

Факультет вычислительной математики и кибернетики МГУ имени М.В. Ломоносова



Программа профессиональной переподготовки «Машинное обучение и управление большими данными»


Тема: Сервис анализа и прогнозирования репутации компаний

ФИО слушателя:

Ратманская Анастасия

ФИО научного руководителя:

**Мочалова Ю.Д., сотрудник ФИЦ ИУ РАН,
специалист по машинному обучению на
больших данных**





Цели и задачи



Цель:

- Создать инструмент, который помогает пользователям анализировать репутацию компаний и прогнозирует её изменения

Задачи:

- Сбор и обработка данных из разных источников (API)
- Анализ тональности с помощью BERT
- Визуализация репутационных данных
- Прогнозирование индекса репутации на основе временных рядов



Актуальность



Актуальность сервиса


1. **Растущая потребность в репутационном анализе:** в современном мире репутация компании является важнейшим фактором, влияющим на её рыночную стоимость и доверие потребителей.
2. **Увеличение объёма данных из новостей и социальных медиа** требует автоматизированных решений для мониторинга и анализа.

Преимущества сервиса по сравнению с существующими решениями

1. **Ориентация на простых пользователей:** понятный интерфейс без сложных настроек и возможность быстро получить результаты анализа и прогнозирования, что делает сервис доступным для малых и средних компаний, студентов, исследователей.
2. **Доступность:** минимизация затрат на использование, что особенно важно для малого бизнеса и индивидуальных пользователей.
3. **Узкая специализация:** чёткий фокус на анализе репутации через новости, социальные медиа, простые прогнозы.



Источники данных



FinancialModelingPrep

новости и аналитические отчёты 10-K



BENZINGA

Benzinga

аналитические заметки

Reddit

публикации и комментарии
пользователей




NewsAPI


новости о компаниях





Архитектура и процесс






Итоговый сервис

- Пользователь выбирает компанию и период анализа.
- Система собирает данные, обрабатывает их, выполняя анализ тональности, вычисляет индекс репутации, визуализирует результаты, строит прогноз на основе исторических данных.
- Результаты отображаются пользователю в виде графиков и таблиц.

Репутационный анализ Apple



Изменение цены акций Apple



Репутационный анализ и изменение цены акций компании

Ключевые элементы интерфейса

2025-01-12 22:29:28+00:00	PM plans to 'unleash AI'	Leading tech firms are said to have committed £14bn towards the project,	0.7963148951530457	https://www.bbc.com/news/articles/crr05jykzk
2025-01-12 22:29:09+00:00	Crime blotter: London	Crime in the world of Apple continues with bad guys misusing AirTags in	-0.9987358450889589	https://appleinsider.com/articles/25/01/12/crim
2025-01-12 22:12:28+00:00	PSA: Text scammers	Apple's Messages app has a built-in safeguard to prevent links or phone	-0.9992198944091796	https://appleinsider.com/articles/25/01/12/psa-
2025-01-12 21:45:17+00:00	Apple, Google, Meta and more:	Apple, Google, Meta and other major tech companies are donating	0.8979178667068481	https://www.phonearena.com/news/apple-goo
2025-01-12 21:37:00+00:00	Epic Games CEO Tim Sweeney	Sweeney's remarks follow pledges from several major tech companies,	0.996963918209076	https://www.techspot.com/news/106314-epic-
2025-01-12 20:00:15+00:00	Apple TV+ Canceled 7 TV	As we start 2025, we're looking back at all the TV shows that were canceled by	-0.9838563203811646	https://www.justjared.com/2025/01/12/apple-tv

Список событий, на основании которых проведен анализ




График исторических данных о репутации компании с прогнозом на 3 месяца вперед



Инструменты и технологии

Для сбора данных:



- APIs

<https://docs.benzinga.com/home>

<https://www.reddit.com/dev/api>

<https://site.financialmodelingprep.com/developer/docs>

Для анализа текста:



HUGGING FACE

- BERT: предобученная модель для классификации текста

https://huggingface.co/docs/transformers/v4.47.1/en/model_doc/bert#overview

Для прогнозирования:



- ARIMA: модель временных рядов

<https://www.statsmodels.org/stable/generated/statsmodels.tsa.arima.model.ARIMA.html>

Для визуализации:



- Matplotlib, Plotly

<https://matplotlib.org/>

<https://plotly.com/>

Язык разработки:



- Python

<https://www.python.org/>

Сервис:



- Flet

<https://flet.dev/>



Обработка данных

1. Сбор данных:

API запросы (новости, отчёты, соцмедиа)

2. Обработка:

- очистка данных (удаление стоп-слов и фраз, исключение слишком коротких постов и постов от ботов, постов с большим количеством спецсимволов и эмодзи)
- удаление дубликатов
- исключение переноса строки и пр. для читаемости

3. Приведение данных к единой структуре и объединение в один датасет

4. Анализ тональности:

Расчёт репутационного индекса (тональность текста с помощью модели BERT)

Дата, Заголовок, Описание, URL, Индекс, Тип

2025-01-04 22:04:52+00:00,"My Tesla got hit while parked on my street, what can I do to get the other insurance to fix it?","https://i.redd.it/dwq8x8d0z0be1.jpeg",-0.9995947480201721,twit

2025-01-03 10:50:05+00:00,Las Vegas Cybertruck explosion investigators piece together suspect's final hours,Matthew Livelsberger -- the driver of the Tesla Cybertruck that exploded outside the Trump International Las Vegas Hotel -- died from a self-inflicted gunshot wound.,https://abcnews.go.com/US/las-vegas-cybertruck-explosion-investigators-piece-suspects-final/story?id=117291682,-0.9980740547180176,news

2023-01-18 16:59:30+00:00,Put Buying In Tesla And The Consumer Discretionary Sector Suggest Higher Prices,"According to CBOE sentiment data, over eight times more money is going into Tesla, Inc. puts than Tesla calls. There is a similar high ratio for the entire consumer discretionary sector, represented by the Consumer Discretionary Select Sector SPDR ETF.",https://seekingalpha.com/article/4570714-put-buying-in-tesla-and-the-consumer-discretionary-sector-suggest-higher-prices,-0.99,news_fm

2023-01-18 15:56:00+00:00,Elon Musk depicted as liar and visionary in Tesla tweet trial,Elon Musk was depicted Wednesday as either a liar who callously jeopardized the savings of "regular people" or a well-intentioned visionary as attorneys delivered opening statements at a trial focused on a Tesla buyout that never happened.,https://www.marketwatch.com/story/elon-musk-depicted-as-liar-and-visionary-in-tesla-tweet-trial-01674075387,0.97,news_fm


2023-01-18 14:31:25+00:00,Tesla Stock Suddenly On The Rise In 2023 - The Latest News That's Fueling The Climb,"After a dismal 2022, Tesla stock has seen a nice increase so far in 2023. Here is what is behind the rise in stock and the company's ongoing issues.",https://www.forbes.com/sites/qai/2023/01/18/tesla-stock-suddenly-on-the-rise-in-2023the-latest-news-thats-fueling-the-climb/,1.0,news_fm

2023-01-18 13:59:26+00:00,"Tesla: Price Cuts Significantly Increased Demand, Here Is The Evidence","Tesla, Inc. stock is significantly under pressure due to a variety of reasons: insider selling, increased competition, and a lowering of demand. However, Tesla management has room for price cuts; its EBITDA margin is extraordinarily high.",https://seekingalpha.com/article/4570669-tesla-price-cuts-significantly-increased-demand-here-is-the-evidence,-0.86,news_fm



Анализ исторических данных

Репутационный анализ Apple




- **График динамики репутации компании:**

линейный график на основании данных о тональностях новостей за выбранный промежуток времени, сгруппированных по неделе

- **Изменение цены акций компании:**

линейный график изменения цены акции за выбранный промежуток времени, сгруппированных по неделе

Изменение цены акций Apple



- **Корреляция:**

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$

r = коэффициент корреляции
 x_i = значения переменной x в выборке
 $\bar{x}$ = среднее значение переменной x
 y_i = значения переменной y в выборке
 $\bar{y}$ = среднее значение переменной y

Корреляция Пирсона
(сглаженные данные):

0.41408440903882066

$0 < r < 1$: Положительная
линейная связь (чем выше
значение, тем сильнее связь)



Прогноз репутации

Обучение модели ARIMA

Подготовка данных

Загрузка и первичная обработка

- Удаление пропусков и дубликатов
- Приведение формата даты и сортировка по дате
- Установка даты как индекса – для временных моделей

Группировка и агрегация данных

- **Группировка по неделям** для устранения избыточной детализации

Создание новых признаков

- **Присвоение весов:** аналитические отчеты и заметки финансовых аналитиков будут иметь больший вес, чем новости из Медиа, а заметки пользователей социальных сетей – наименьший вес
- Временной ряд анализируется на основании weighted score

Нормализация данных

- Приведение данных к единому масштабу для лучшей обработки моделью

Сглаживание временного ряда

- В данном случае **сглаживание НЕ применяется**, так как это может исказить структуру ряда, модель ARIMA может самостоятельно выявлять тренды

Проверка стационарности ряда

- В данном случае ряд является **стационарным**, так как среднее и дисперсия остаются постоянными со временем

Min-max нормализация
Приведение данных в диапазон [0, 1]

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}}$$


ADF Statistic: -10.890075144583436
p-value: 1.2315202309632689e-19
Ряд стационарен



Прогноз репутации

Обучение модели ARIMA Подбор параметров и оценка

ARIMA Forecast vs Actual (Weekly)



- Модель сглаживает данные (делает прогноз, основываясь на средних тенденциях, что может привести к снижению амплитуды)
- Отсутствие важных признаков (например, макроэкономические факторы, которые могли бы объяснить колебания)

Подбор параметров модели

- p (порядок авторегрессии): Количество прошлых значений ряда, используемых для предсказания. $p = 6$
- d (порядок дифференцирования): Количество раз, когда ряд был дифференцирован для приведения его к стационарности. $d = 1$ (первое дифференцирование)
- q (порядок скользящего среднего): Количество прошлых ошибок (остатков), используемых для предсказания. $q = 6$

Оценка модели

Метрики точности модели:

MAE (Mean Absolute Error): 0.1553 абсолютное отклонение предсказаний от истинных значений

MSE (Mean Squared Error): 0.0569

RMSE (Root Mean Squared Error): 0.2385 ошибка $\approx 23,85 \%$



Видео демонстрация

Reputation Analysis

Home

Reputation analysis

Events

Forecast

Choose company

Choose period

Analyze reputation

Reputation forecast for next 3 months



Выводы и перспективы развития

Вывод

- В рамках исследовательской работы была проведена всесторонняя обработка данных, построение модели прогнозирования и её обучение на реальных данных.
- Сервис находится на стадии минимально жизнеспособного продукта (MVP) и готов к тестированию в реальных условиях.

Перспективы развития

- Включение макроэкономических данных (динамика ВВП, уровень инфляции и пр.)
- Расширение источников данных
- Углубленный анализ факторов, влияющих на репутацию



Список литературы



1. Endpoint [Электронный ресурс] // Точка качества. URL: <https://tquality.ru/blog/kak-pisat-endpointy/> (дата обращения 30.11.2024).
2. Нильсен Э. Практический анализ временных рядов. Учебник -М.: Диалектика (Вильямс), 2021.
3. Анализ временных рядов [Электронный ресурс] // Хабр. URL: <https://habr.com/ru/companies/otus/articles/732080/> (дата обращения 22.12.2024).
4. Трансформеры [Электронный ресурс] // Яндекс образование. URL: <https://education.yandex.ru/handbook/ml/article/transformery> (дата обращения 20.12.2024).
5. Маккинни У. Python и анализ данных. ДМК, 2015



Спасибо за внимание!